

Mini-projet TCSD

1 Partie 1 : Déploiement d'un *cluster* de 3 - 4 machines

Dans cette première partie, il est demandé de mettre en place un *cluster* Hadoop virtuel composé de 3 ou 4 machines (un *NameNode* et deux ou trois *DataNodes*).

2 Partie 2

L'objectif est de traiter les données avec un des outils de l'écosystème Hadoop (différent des outils déjà vus en TDs, ex. SPARK) sur le *cluster* construit à la partie 1. Fixer un objectif ambitieux, combiner vos savoirs existants et apprendre à en apprendre de nouveaux pour réussir au mieux votre projet.

- Récupérez des données sur data.gouv.fr (ou autre). Le choix de jeu de données est libre. Vous avez la possibilité de choisir des csv et/ou autres fichiers que vous souhaitez.
- Chargez le jeu de données sur le *cluster*.
- Manipulez les données chargées avec l'outil choisi.
- Visualisation des résultats.

3 Partie 3 (bonus)

- La configuration de Kerberos sur le *cluster*.
- L'aspect écologique : impact environnementale, estimation électrique du *cluster*, ... etc.
 - <https://www.greenit.fr/>
 - <https://ecoinfo.cnrs.fr>
 - <https://impactometre.fr/>

A rendre

- Un compte rendu (PDF) avec les étapes pour réaliser les parties 1 et 2 à déposer sur la rubrique adéquate dans Moodle.
- Travail en binôme ou en monôme.
- Date limite : 31/01/2026.

Eléments de notation

- Clarté du compte rendu : explication détaillée des étapes (commandes, captures d'écran, ... etc).
- Structuration du compte rendu, présentation, orthographe, ... etc.
- Le choix de jeu de données.
- Le choix du composant Hadoop utilisé pour le traitement.
- Tolérance zéro au plagiat.